

مینی پروژه اول

درس:

یادگیری ماشین

نیمسال اول تحصیلی

۱۴۰۴-۱۴۰۵

تاریخ تحویل

۱۴۰۴/۰۹/۱۰

امید طالبی

گام اول – بارگذاری مجموعه داده و تحلیل اولیه	۳.....
گام دوم – پیش پردازش	۵.....
گام سوم – پیاده سازی الگوریتم logistic Regression	۱۰.....
گام چهارم – نمودار همگرایی و تحلیل نرخ یادگیری	۱۳.....
گام پنجم – الگوریتم Naïve Bayes	۱۴.....
گام ششم – ترسیم مرز تصمیم	۱۶.....

❖ شرح مراحل انجام پروژه

گام اول – بارگذاری مجموعه داده و تحلیل اولیه

در فایل کد پروژه به سری اطلاعات آماری را میتوان خواهید خواند. به عنوان نمونه میتوان تعداد سطرها ، و تعداد ستون ها ، نوع ستون ، تعداد مقادیری که نال ، به سری اطلاعات آماری مثل میانگین ، واریانس ، کمترین مقدار داده و بیشترین مقدار داده و.... رو میتوان مشاهده نمود.

❖ به نظر شما چه شغلی بیشتر در معرض اضطراب قرار دارد؟ (پاسخ این سوال جزو اهداف این پروژه نیست، اما به شما برای درک بهتر مجموعه داده کمک خواهد نمود.)

برای محاسبه اینکار من از دوره استفاده کردم :


راه اول : در ابتدا اومدم ستون (1-10) Anxiety Level را با توجه به شغل اومدم groupby کردم و سپس میانگین گرفتم در انتها مقدار استرس در هر حرفه به صورت میانگین بدست آمد.

```
Occupation
Lawyer      4.206428
Doctor      4.199525
Engineer    4.138055
Scientist   4.062500
Freelancer  3.952267
Student     3.883827
Athlete     3.871046
Nurse       3.854820
Chef        3.840326
Artist      3.796171
Musician    3.789238
Other       3.764286
Teacher     3.749690
Name: Anxiety Level (1-10), dtype: float64
```

راه حل دوم این بود که در ابتدا اومدم کل ستون Anxiety Level (1-10) را انتخاب کردم و سپس یک شرط گذاشتم و مقادیر آن را به صورت باینری در آوردم ، در صورتی که مقدار استرس از ۵ بزرگتر مساوی بود عدد یک و در صورتی که کمتر از ۵ بود مقدار صفر را قرار دادم و سپس با توجه به این مقادیر بدست آمده باز group by زدم و میانگین گرفتم و خروجی زیر بدست آمد :

```
Occupation
Doctor      0.359857
Lawyer      0.359703
Engineer    0.352941
Scientist   0.344952
Freelancer  0.306683
Student     0.305239
Nurse       0.298490
Chef        0.298368
Athlete     0.283455
Artist      0.281532
Musician    0.281390
Other       0.269048
Teacher     0.258984
Name: binary_anxiety, dtype: float64
```

و در ادامه نیز تعداد کل مشاغل را جهت اطمینان درآورده (۱۳ تا بود) و به صورت نمودار نمایش داده



شد.

گام دوم – پیش پردازش

۲-الف) در این بخش بررسی کنید که آیا داده گمشده وجود دارد یا خیر؟

با دستور `info` و `isnull` میتوان تعداد داده های گمشده در هر ستون را بررسی کرد که در خروجی زیر میتوان مشاهده نمود که هیچ داده نالی وجود ندارد.

`df.info()`

```
#      Column      Non-Null Count
---  -
0     Age      11000 non-null
1     Gender   11000 non-null
2     Occupation 11000 non-null
3     Sleep Hours 11000 non-null
4     Physical Activity (hrs/week) 11000 non-null
5     Caffeine Intake (mg/day) 11000 non-null
6     Alcohol Consumption (drinks/week) 11000 non-null
7     Smoking   11000 non-null
8     Family History of Anxiety 11000 non-null
9     Stress Level (1-10) 11000 non-null
10    Heart Rate (bpm) 11000 non-null
11    Breathing Rate (breaths/min) 11000 non-null
12    Sweating Level (1-5) 11000 non-null
13    Dizziness  11000 non-null
14    Medication 11000 non-null
15    Therapy Sessions (per month) 11000 non-null
16    Recent Major Life Event 11000 non-null
17    Diet Quality (1-10) 11000 non-null
18    Anxiety Level (1-10) 11000 non-null
dtypes: float64(3), int64(9), object(7)
memory usage: 1.6+ MB
```

`df.isnull().sum()`

```
Age      0
Gender    0
Occupation 0
Sleep Hours 0
Physical Activity (hrs/week) 0
Caffeine Intake (mg/day) 0
Alcohol Consumption (drinks/week) 0
Smoking   0
Family History of Anxiety 0
Stress Level (1-10) 0
Heart Rate (bpm) 0
Breathing Rate (breaths/min) 0
Sweating Level (1-5) 0
Dizziness  0
Medication 0
Therapy Sessions (per month) 0
Recent Major Life Event 0
Diet Quality (1-10) 0
Anxiety Level (1-10) 0
dtype: int64
```

۲-ب) به نظرتان اگر داده گمشده بود چه کاری باید انجام دهیم؟

در اینجا به علت هایی که داده ها نیستند پرداخته و در ادامه راهکارها رو خواهیم گفت.

۱ - Missing Completely at Random (MCAR)

در این مورد از دست رفتن داده کاملاً تصادفی بوده و به مقدار خودش و ستون های دیگر و به گروه خاص ارتباط ندارد. برای مثال بعد از اینکه ما با اپراتور با تلفن صحبت میکنیم ، اپراتور میگه در صورت تمایل به پاسخگویی نمره ۱ تا ۵ بدهید که تماسی که من برقرار میکنم و امتیازی که نمیدم هیچ ارتباطی با تماس دیگر ندارد.

۲ - Missing at Random (MAR)

گم شدن داده به خودش وابسته نیست و به ستون یا ویژگی های دیگر در دیتاست وابسته است. برای مثال ممکن است در بعضی از فرم ها خانم ها سن یا وزنشان را کمتر از آقایون وارد کنند.

۳ - Missing Not at Random (MNAR)

در این حالت گم شدن دیتا به این دلیل است که فردی که میخواهد اطلاعات را وارد کند چون مقدار آن خیلی زیاد یا خیلی کم یا خاص هست از وارد کردن آن جلوگیری میکند. برای مثال میخواهد فرد وام بگیرد ولی داخل اطلاعات ، وضعیت خانه خود (استیجاری ، صاحب خانه) را پر نمیکند.

در ادامه راه حل های و راهکارهای پر کردن دیتا برای missing value را خواهیم داشت :

۱- میتوان با استفاده از mean , median مقادیر، نال رو پر کرد.

۲- در صورتی که داده به صورت categorical از مد استفاده کنیم.

۳- از متد Forward Fill and Backward Fill استفاده کنیم.

Forward fill

	date	fruit	price
0	2021-01-01	apple	0.8
1	2021-01-02	apple	NaN
2	2021-01-03	apple	NaN
3	2021-01-04	apple	1.2
4	2021-01-01	mango	NaN
5	2021-01-02	mango	3.1
6	2021-01-03	mango	NaN
7	2021-01-04	mango	2.8

	date	fruit	price
0	2021-01-01	apple	0.8
1	2021-01-02	apple	0.8
2	2021-01-03	apple	0.8
3	2021-01-04	apple	1.2
4	2021-01-01	mango	1.2
5	2021-01-02	mango	3.1
6	2021-01-03	mango	3.1
7	2021-01-04	mango	2.8

Backward fill

	date	fruit	price
0	2021-01-01	apple	0.8
1	2021-01-02	apple	NaN
2	2021-01-03	apple	NaN
3	2021-01-04	apple	1.2
4	2021-01-01	mango	NaN
5	2021-01-02	mango	3.1
6	2021-01-03	mango	NaN
7	2021-01-04	mango	2.8

	date	fruit	price
0	2021-01-01	apple	0.8
1	2021-01-02	apple	1.2
2	2021-01-03	apple	1.2
3	2021-01-04	apple	1.2
4	2021-01-01	mango	3.1
5	2021-01-02	mango	3.1
6	2021-01-03	mango	2.8
7	2021-01-04	mango	2.8

البته میتوان از روش های آماری دیگر که به صورت متد هستند نیز استفاده کرد :

برای مثال MICE (Multiple Imputation) که روش بسیار خوبی هست و به صورت زیر عمل میکند :

۱- هر ستون دارای missing به صورت شرطی و چندباره تخمین زده می شود

۲- uncertainty (عدم قطعیت) را هم مدل می کند

۳- نتایج بسیار واقعی تر هستند

البته روش های دیگری هم وجود دارد.

۲-پ) کار دیگری که بایستی در این مرحله انجام شود، مقیاس کردن داده هاست. در این قسمت کتابخانه scikit-learn میتواند به شما کمک نماید.

من داده های عددی رو با استفاده از standardscaler استفاده کردم و برای داده ای متنی که ۰ و ۱ یا TRUE OR FALSE بودن از OrdinalEncoder استفاده کردم و برای شغل که نمیخواستم از ordinal encoder استفاده کنم از one_hot_encoder استفاده کردم.

۲ ت-) داده ها را به دو قسمت train و test تقسیم نمایید. همینطور برای اینکه درک و حسی از داده بگیرید، به کمک کتابخانه matplotlib آن را رسم کنید.

در فایل کد میتوانید جزئیات بیشتر ملاحظه بفرمایید.

۲-ث) چرا feature standardization در قسمت پیش پردازش اهمیت دارد و اگر آن را انجام ندهیم چه اتفاقی

رخ خواهد داد که دقت مدل را لکه دار خواهد کرد؟

در صورتی که استاندارد سازی نکنیم مدل ما دچار خواهد شد مثلا در فایل داده ما ، برای مثال میزان مصرف کافئین معمولا عددی بزرگ هست مثلا ۴۰۰ ولی از آنطرف داده میزان خواب عددی کمتر از ۱۰ هست. این به این معنی نیست که اهمیت کافئین در صورت استاندارد سازی ۴۰ برابر از خواب است ولی این یک تعبیر غلط هست به همین دلیل با داده های خودمون را استاندارد کنیم از طرف در صورت استاندارد نکردن مدل ریاضی ما دچار این میشود که کافئین چون مقدار خیلی بیشتری دارد مهمتر از ستون دیگر هست و به آن وزن بیشتری خواهد داد که این منطق اشتباه است. بعد از این کار باعث میشود که تمام ویژگی ها استاندارد شده و سبب این میشود که اون ویژگی هایی که با اضطراب واقعا رابطه دارند ، ضریب بالایی بگیرند. یکی از راه هایی که میتوان از آن استفاده کرد ، استفاده از min-max هست یعنی کمترین داده رو ۰ و بیشترین داده رو ۱ قرار بدیم. و مابقی داده ها هم وسط ۰ و ۱ قرار میگیرند.

۲-ج) شاید چالشی که با آن مواجه شوید، رسم نمودار باشد، زیرا این مجموعه داده ۸ ویژگی دارد. به نظر شما چگونه

میتوان در یک نمودار که فضای دو بعدی دارد، ۸ ویژگی را نشان داد؟

همانطور که در کلاس درس داشتیم ، دو رویکرد داریم :

۱- استفاده از feature selection

۲- استفاده از feature extraction

که یکی از الگوریتم هایی که میتوان استفاده کرد pca میباشد. که میتوان بعد رو کاهش داد. به حالت دیگه این بود که پیام خودمون دو ویژگی مثلا سن و استرس را نمایش دهیم.

گام سوم-پیاده سازی الگوریتم Logistic Regression

۳-الف) خب در این قسمت باید الگوریتم LR را پیاده سازی کنید

Logestic regression (یک الگوریتم کلاسیفیکیشن یا طبقه بند هست)

Sigmoid (logistic) function:

یک تابع داریم به اسم سیگموئید که برابر است

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

تابع cost function برابر است با :

$$L(g(z_i), y_i) = \begin{cases} -\log(g(z_i)) & \text{if } y_i = 1 \\ -\log(1 - g(z_i)) & \text{if } y_i = 0 \end{cases}$$

این می‌گه اگر کلاس واقعی یک باشد و ما پیش بینی کرده باشیم ۰.۹ و چون مقدار که پیش بینی کردیم نزدیک هست به کلاس واقعی پس مقدار loss در این صورت مقدار کم باشد.

$$L \Rightarrow -\log 0.9 = 0.1054 \text{ (مقدارش نزدیک به ۰ هست)}$$

که در این حالت همونطور که میبینم مقدار loss نزدیک به صفر دارد به این معنی که تقریباً درست گفتیم.

الته میتوان فرمول بالا رو با هم ترکیب کرد .

$$L(g(z_i), y_i) = -y_i \log(g(z_i)) - (1 - y_i) \log(1 - g(z_i))$$



$$C(w, b) = \frac{1}{m} \sum_{i=1}^m L(g(z_i), y_i)$$



$$C(w, b) = \frac{1}{m} \sum_{i=1}^m [-y_i \log(g(z_i)) - (1 - y_i) \log(1 - g(z_i))]$$

Minimise

gradient descent

حال برای محاسبه گرادیان دیسنت باید مشتق z را یکبار بر حسب w و بار دیگر بر حسب b محاسبه کرده :

$$z_i = \vec{w} \cdot \vec{x}_i + b \quad L(g(z_i), y_i) = -y_i \log(g(z_i)) - (1 - y_i) \log(1 - g(z_i))$$

$$g(z_i) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x}_i + b)}} \quad C(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m L(g(z_i), y_i)$$

$$\boxed{\frac{\partial L}{\partial b}} = \frac{\partial L}{\partial g_i} \cdot \frac{\partial g_i}{\partial b} = \frac{\partial L}{\partial g_i} \cdot \frac{\partial g_i}{\partial z_i} \cdot \frac{\partial z_i}{\partial b}$$

$$= \left(\frac{g_i - y_i}{g_i(1 - g_i)} \right) \cdot g_i(1 - g_i) \cdot 1$$

$$= g_i - y_i$$

$$\boxed{\frac{\partial C}{\partial b}} = \frac{1}{m} \sum_{i=1}^m (g_i - y_i)$$

$$\frac{\partial L}{\partial w_j} = \frac{\partial L}{\partial g_i} \cdot \frac{\partial g_i}{\partial w_j} = \frac{\partial L}{\partial g_i} \cdot \frac{\partial g_i}{\partial z_i} \cdot \frac{\partial z_i}{\partial w_j}$$

$$= \left(\frac{g_i - y_i}{g_i(1 - g_i)} \right) \cdot g_i(1 - g_i) \cdot x_{i,j}$$

$$= (g_i - y_i) \cdot x_{i,j}$$

$$\boxed{\frac{\partial C}{\partial w_j}} = \frac{1}{m} \sum_{i=1}^m (g_i - y_i) \cdot x_{i,j}$$

حال از این موارد برای پیاده سازی تابع logistic rerresion استفاده میکنیم.

۳-ب) دستیابی به دقت بالاتر منوط به انتخاب درست هایپر پارامترهاست. به نظر شما چه مقادیری بایستی به آنها بدهیم تا خطا کمتر بشود؟


میتونیم learning rate را مقدارشو کمتر کنیم و از آن طرف iteration را مقدار زیاد کنیم البته در این حالت محاسبات زیادتر باید انجام شود البته در صورتی که alpha خیلی بزرگ باشد مدل واگرا میشود و اگر هم مقدارش خیلی کم باشد ، قبل از رسیدن به نقطه بهینه ، متوقف میشود. و در صورتی که iteration کم باشد مدل نمیتونه خوب یادبگیرد ، و ممکن هست سبب underfit شود. و اگر هم خیلی زیاد باشد سبب این میشه که مدل ، ان نویز های داده تست را هم یادبگیرد باعث overfit شدن شود.

و نکته ای دیگه که میتونه تاثیر گذار باشه سایز batch میباشد که :

- ۱- اگه کل داده ها رو بررسی کنیم همگرایی صاف و بسیار کند خواهد بود
- ۲- اگه سایز batch یک باشه ، همگرایی بسیار نوسانی خواهد بود و با هر تغییر میره تغییرات رو یاد میگیره

- ۳- یه حالت میانی هم داره به اسم mini_batch که سایز batch را معمولا توانی از ۲ میگیریم که این میتواند خوبی های موارد بالا رو داشته باشد مثلا (۴ و ۸ و ۱۶ و ۳۲ و ۶۴) البته مشخص کردن این مقدار به تعداد داده های اصلی هم بستگی دارد

گام چهارم-نمودار همگرایی و تحلیل نرخ یادگیری



۴-ب) از این نمودار چه نتیجه ای میگیرید؟

هر چه نرخ یادگیری بسیار کوچک باشد ، همگرایی پایدار و ایمن را تضمین میکند اما مشکلی که در این حالت به وجود میاد ، فرایند آموزش بسیار کند خواهد شد.

رفتار خط سبز به این شکل هست که به طور مداوم نوسان میکند و هرگز در یک نقطه پایین ثابت نمیشود. به همین مدل نزدیک به نقطه بهینه میرسد اما به دلیل گام های بزرگش ، نوسان میکند.

رفتار خط قرمز به این شکل خواهد بود که به شدت نوسان میکند و در بالاترین محدوده باقی می ماند. و نشان میدهد که این مدل برای یادگیری مدل بیش از حد بزرگ است و با هر بار بروزرسانی پارمتر، مدل از نقطه بهینه دور میشود و نمیتونه خیلی خوب فرایند یادگیری رخ دهد.

به همین دلیل یک trade off خواهیم بین سرعت و پایداری. اگر α مقدار خیلی کم باشد مثل خط آبی ممکن است در حداقل های محلی گیر کند و جواب بهینه ندهد.

گام پنجم-الگوریتم Naïve Bayes

۵-الف)

۵-ب)

Model	NB	LR	LR scratch
Accuracy	0.810303	0.842121	0.842121
Precision	0.75601	0.795987	0.795328
Recall	0.597909	0.678707	0.679658
F1-Score	0.667728	0.732683	0.732957
AUC-ROC	0.88497	0.913493	0.913492
Log Loss	0.455134	0.3371	0.337051

همانطور که از معیار های بالا میتوان دید Logistic Regression نسبت NaïveBaye بهتر است.

Accuracy

رگرسیون لجستیک ۳ درصد دقیق تر است. یعنی در کل، تعداد بیشتری از آدمها را درست تشخیص داده است.

Recall

NaïveBaye نمره پایینی (۰.۵۹) گرفته است. یعنی از هر ۱۰۰ فرد مضطرب، ۴۱ نفر را تشخیص نداده و به خانه فرستاده است! اما رگرسیون لجستیک توانسته ۶۷ نفر را شناسایی کند. در پزشکی، این یعنی LR مدل امن تری است.

AUC سطح زیر نمودار


AUC بالای ۰.۹ (برای LR) یعنی مدل شما "عالی" عمل کرده است. مدل NB با ۰.۸۸ در دسته "خوب" قرار می گیرد.

Log Loss

NaïveBaye فرض می کند ویژگی ها مستقل هستند (مثلاً خواب ربطی به استرس ندارد). اما در دنیای واقعی و دیتای شما، ویژگی ها همبستگی دارند (خواب کم باعث استرس می شود). رگرسیون لجستیک این روابط را بهتر درک کرده و مدل دقیق تری ساخته است.

گام ششم-ترسیم مرز تصمیم

۶- الف) نمودار مرز تصمیم برای روش Naïve Bayes و Logistic Regression را رسم کنید.



۶-ب) این نمودارها را مقایسه نمایید. تحلیل شما از نتایج تان چگونه است؟

خط صاف

رگرسیون لجستیک به مدل خطی که سعی می‌کند به خط درست کنه تا دو گروه داده‌ها را از هم جدا کند.

تو نمودار، می‌بینی که داده‌های گروه سالم (آبی) و مضطرب (قرمز) با یک خط صاف از هم جدا شدن.

یعنی LR تونسته به مرز ساده و مستقیم برای دسته‌بندی درست پیدا کند.

منحنی (قوس‌دار)

Naïve Bayes فرض می‌کند داده‌های هر گروه مثل یک زنگوله (توابع نرمال) پخش شدن. مرز جداسازی هم جاییه که

این زنگوله‌ها با هم تلاقی می‌کنن.

تو نمودار، مرز جداسازی حالت خمیده داره (شیب بیضی یا سهمی). یعنی مرزش منعطف‌تره نسبت به LR.

با اینکه NB مرز منحنی داره و تو داده‌های پیچیده مفیده، ولی تو این داده‌ها LR بهتر عمل کرده. دلیلش هم اینه که داده‌ها در فضای PCA به اندازه کافی قابل جداسدن خطی بودن، و NB فرض می‌کنه ویژگی‌ها مستقل هستن، در حالی که مثلاً "ساعات خواب" و "استرس" به هم ربط دارن، پس کمی گیج می‌شه LR. اما می‌تونه این ربط‌ها رو در ضرایبش لحاظ کنه و عملکردش بهتره.